

Análise Exploratória de Dados e Redução de Dimensionalidade na Avaliação da Qualidade de Vinhos

João Victor Carneiro de Oliveira
Departamento de Engenharia de Teleinformática (DETI)
Universidade Federal do Ceará (UFC)
Fortaleza, Brasil
vcovictor@alu.ufc.br

Leonardo Dayvison S. de Almeida Teixeira
Departamento de Engenharia de Teleinformática (DETI)
Universidade Federal do Ceará (UFC)
Fortaleza, Brasil
leodayvison@alu.ufc.br

Ludmila Maria Pires de Oliveira
Departamento de Engenharia de Teleinformática (DETI)
Universidade Federal do Ceará (UFC)
Fortaleza, Brasil
ludmilamariapo55@gmail.com

Maria Lissa Rodrigues Costa
Departamento de Engenharia de Teleinformática (DETI)
Universidade Federal do Ceará (UFC)
Fortaleza, Brasil
marialissa@alu.ufc.br

Abstract—Este artigo apresenta uma análise exploratória de dados e a aplicação da Análise de Componentes Principais (PCA) no conjunto de dados de vinho branco português, o Vinho Verde, visando à preparação da base para o desenvolvimento de modelos preditivos em Inteligência Computacional. A partir de um conjunto com $N = 4897$ amostras e 11 atributos físico-químicos, foram conduzidas análises estatísticas univariadas (incondicionais e condicionais à classe) e bivariadas. Os resultados revelaram forte sobreposição de distribuições entre as classes de qualidade, além de distribuições não gaussianas com presença de assimetria e *outliers* em determinadas variáveis preditoras. Ainda foi possível perceber o teor alcoólico e a acidez volátil como variáveis de maior potencial discriminativo individual. A análise bivariada evidenciou redundâncias significativas, como a forte correlação entre densidade, açúcar residual e álcool, justificando a redução de dimensionalidade. Por fim, a projeção 2D via PCA confirmou a alta complexidade e a ausência de separabilidade linear simples entre os níveis de qualidade, indicando uma leve tendência de agrupamento de vinhos de alta qualidade associados a menor densidade e maior teor alcoólico. A análise reforça a necessidade de padronização dos dados e do uso de modelos de aprendizado não lineares para a classificação precisa da qualidade.

I. INTRODUÇÃO

A elaboração de modelos preditivos no campo da *Inteligência Computacional Aplicada* têm se consolidado como pilar no desenvolvimento de ferramentas que auxiliam na solução de problemas complexos de classificação e regressão em diversos domínios acadêmicos e industriais. Sob essa perspectiva, é importante destacar que o sucesso e a qualidade de qualquer modelo preditivo dependem fundamentalmente do manejo e do tratamento correto aplicado previamente aos dados utilizados. Com essa finalidade, artifícios de exploração

de dados e técnicas de redução de dimensionalidade, no caso de grandes conjuntos de dados, são amplamente aplicados no aprendizado de máquina, permitindo a identificação de relações ocultas, avaliação de distribuições e eliminação de redundâncias. Nesse contexto, este artigo trabalha com a **análise exploratória e a redução da dimensionalidade como preparação para o desenvolvimento de um modelo para avaliação da qualidade de vinhos**.

No setor vinícola, a avaliação dos vinhos produzidos é tradicionalmente realizada por testes sensoriais, o que, apesar da acurácia garantida por especialistas, ainda constitui um processo subjetivo e dispendioso. Assim, a utilização de parâmetros físico-químicos mensuráveis, tais como teor alcoólico e pH, surge como suporte para a predição da qualidade da bebida. Contudo, faz-se importante destacar que as correlações entre esses atributos por vezes não são evidentes, além de elevar a complexidade computacional dos modelos de classificação, bem como introduzem erros intrínsecos e ruídos. Para mitigar esses desafios, o presente artigo apresenta uma análise estatística minuciosa e a aplicação da *Análise de Componentes Principais (PCA)* sobre o conjunto de dados abordado, tendo como objetivo principal mapear as propriedades estatísticas univariadas, bivariadas e multivariadas dos descritores, avaliando seu poder discriminativo e preparando a base de dados para o posterior desenvolvimento de modelos de *Inteligência Computacional Aplicada*.

II. METODOLOGIA

Nesta seção, apresentamos o procedimento metodológico adotado para a condução da análise exploratória e do pré-processamento do conjunto de dados. Em geral, são descritas as características gerais e a estrutura do dataset utilizado, bem

Os autores agradecem à Professora Doutora Michela Mulas pela orientação e contribuições técnicas durante o desenvolvimento deste artigo.

como, detalham-se as formulações estatísticas aplicadas nas análises univariada e bivariada, além da *PCA* implementada.

A. Descrição Preliminar dos Dados

O conjunto de dados trabalhado consiste em uma matriz numérica cujas linhas representam as $N = 4897$ amostras do vinho branco português, chamado "Vinho Verde", e as colunas, as características medidas para cada amostra. É válido mencionar, também, que o repositório de origem dos dados [1] inclui amostras de mais de um tipo de vinho, entretanto, para a finalidade desse artigo, optamos por selecionar para análise apenas o vinho branco português, por possuir mais amostras disponíveis.

As características presente no conjunto de dados são listadas abaixo:

- Fixed acidity: Concentração de ácido tártaro (g/dm^3);
- Volatile acidity: Concentração de ácido acético (g/dm^3);
- Citric acid: Concentração de ácido cítrico (g/dm^3);
- Residual sugar: Concentração de açúcar residual (g/dm^3);
- Chlorides: Concentração de cloreto de sódio (g/dm^3);
- Free sulfur dioxide: Concentração de dióxido de enxofre livre (mg/dm^3);
- Total sulfur dioxide: Concentração total de dióxido de enxofre (mg/dm^3);
- Density: Densidade do vinho (g/dm^3);
- pH: Potencial Hidrogeniônico
- Sulphates: Concentração de sulfato de potássio (g/dm^3)
- Alcohol: Volume de álcool (vol.%)
- Quality: Qualidade do vinho (classificação inteira entre 0 e 10)

A partir da análise preliminar do conjunto de dados temos, então, que os parâmetros físico-químicos atuam como variáveis preditoras, totalizando $D = 11$ preditores, e que a característica rótulo, *Quality*, possui 11 valores totais distintos, $\{0,10\}$, totalizando $L = 11$ classes. A distribuição entre das amostras entre as classes segue o seguinte gráfico:




Fig. 1. Distribuição de Classes

B. Análise Univariada Incondicional

Na Análise Univariada Incondicional avaliamos isoladamente o comportamento global de cada um dos D preditores,

sem considerar o rótulo das L classes, ou ainda a relação entre múltiplos atributos. Para isso são avaliadas as métricas de tendência central, dispersão e forma, como média (μ_d), desvio padrão (σ_d) e assimetria (γ_d), complementadas por histogramas e *box-plots* calculados sobre a totalidade das N observações.

TABLE I
MEDIDAS DE TENDÊNCIA CENTRAL PARA ANÁLISE UNIVARIADA INCONDIACIONAL

	Média(μ)	Desvio Padrão(σ)	Assimetria(γ)
fixed acidity	6.854788	0.843868	0.647751
volatile acidity	0.278241	0.100795	1.576980
citric acid	0.334192	0.121020	1.281920
residual sugar	6.391415	5.072058	1.077094
chlorides	0.045772	0.021848	5.023331
free sulfur dioxide	35.308085	17.007137	1.406745
total sulfur dioxide	138.360657	42.498065	0.390710
density	0.994027	0.002991	0.977773
pH	3.188267	0.151001	0.457783
sulphates	0.489847	0.114126	0.977194
alcohol	10.514267	1.230621	0.487342




Fig. 2. Histogramas Univariados Incondicionais

A partir da análise das medidas, {Tabela 1 e Figuras 2 e 3}, podemos notar um comportamento importante a ser destacado em certas características, as quais não apresentam distribuição gaussiana normal, ou seja, assimetria acentuada, bem como tem presença significativa de *outliers* nos *box-plots*. Esse comportamento é perceptível em preditores como *chlorides* e *volatile acidity*. Além disso, observa-se uma variação substancial nas magnitudes das métricas, o que pode sugerir a necessidade de técnicas de padronização em uma futura aplicação do PCA.

C. Análise Univariada Condicional à Classe

Na Análise Univariada Condicional à Classe avaliamos isoladamente o comportamento dos preditores, mas, agora, divididos segundo o rótulo das L classes. Isto é, as medidas de




Fig. 3. Box-plots Univariados Incondicionais

tendência são calculadas com base nas observações, $N_L < N$, pertencentes a cada classe específica. O objetivo central dessa análise é identificar o poder discriminativo dos atributos, ou seja, verificar se alguma variável isolada possui capacidade de separar ou diferenciar as classes entre si.




Fig. 4. Box-plots Univariados Condicionais à Classe

Os resultados obtidos, {Tabelas 2 e 3, e Figuras 4 e 5}, evidenciaram que a maioria dos atributos isolados apresenta expressiva sobreposição de distribuições entre as classes, indicando baixo poder discriminativo individual. As exceções destacadas foram o teor alcoólico (*alcohol*), que apresentou

correlação positiva direta com o aumento da qualidade, e a acidez volátil (*volatile acidity*), que exibiu comportamento inverso.

D. Análise Bi-variada Incondicional

A análise bivariada incondicional consiste na avaliação simultânea de pares de variáveis preditoras, considerando a totalidade das N observações da base de dados, sem dividir as amostras pelas classes do rótulo-alvo L . Seu objetivo principal é examinar a existência de relações de dependência ou associação entre dois atributos por meio de gráficos de dispersão/scatter plots, além de identificar a presença de alta redundância de informação entre as variáveis.




Fig. 5. Mapa de Calor Bivariado Incondicional




Fig. 6. Scatterplots Bivariados Incondicionais

TABLE II
MÉDIAS CONDICIONAIS POR QUALIDADE

quality	fixed acidity	volatile acidity	citric acid	residual sugar	chlorides	free sulfur dioxide	total sulfur dioxide	density	pH	sulphates	alcohol
3	7.600000	0.333250	0.336000	6.392500	0.054300	53.325000	170.600000	0.994884	3.187500	0.474500	10.345000
4	7.129448	0.381227	0.304233	4.628221	0.050098	23.358896	125.279141	0.994277	3.182883	0.476135	10.152454
5	6.933974	0.302011	0.337653	7.334969	0.051546	36.432052	150.904598	0.995263	3.168833	0.482203	9.808840
6	6.837671	0.260564	0.338025	6.441606	0.045217	35.650591	137.047316	0.993961	3.188599	0.491106	10.575372
7	6.734716	0.262767	0.325625	5.186477	0.038191	34.125568	125.114773	0.992452	3.213898	0.503102	11.367936
8	6.657143	0.277400	0.326514	5.671429	0.038314	36.720000	126.165714	0.992236	3.218686	0.486229	11.636000
9	7.420000	0.298000	0.386000	4.120000	0.027400	33.400000	116.000000	0.991460	3.308000	0.466000	12.180000

TABLE III
TABELA DE DESVIOS PADRÃO PARA ANÁLISE UNIVARIADA CONDICIONAL À CLASSE

quality	fixed acidity	volatile acidity	citric acid	residual sugar	chlorides	free sulfur dioxide	total sulfur dioxide	density	pH	sulphates	alcohol
3	1.724743	0.140827	0.081460	5.317332	0.046468	69.420776	107.758331	0.002831	0.209834	0.119845	1.224089
4	1.081490	0.173463	0.163857	4.163610	0.025888	20.391349	52.753769	0.002462	0.163691	0.117973	1.003217
5	0.838433	0.100066	0.140814	5.327619	0.026496	18.145991	44.086187	0.002545	0.140895	0.098205	0.847065
6	0.837442	0.088142	0.119325	5.166625	0.020453	15.735679	41.286220	0.003024	0.150996	0.113357	1.147776
7	0.755670	0.091106	0.079183	4.297989	0.010697	13.244737	32.742982	0.002768	0.158402	0.130195	1.246536
8	0.819337	0.108029	0.085439	4.263391	0.013164	16.203675	33.006329	0.002788	0.152289	0.147073	1.280138
9	0.983362	0.057619	0.082037	3.759255	0.007436	13.427584	19.824228	0.003118	0.082885	0.092628	1.013410

O mapa de calor, {Figura 5}, e os *scatter-plots*, {Figura 6}, evidenciaram certas dependências lineares e informações redundantes entre certos atributos físico-químicos. Destacam-se as correlações positivas entre *density* e *residual sugar*, e entre *free sulfur dioxide* e *total sulfur dioxide*. Em contrapartida, observou-se uma forte relação inversa entre *density* e *alcohol*. Embora intuitivas do ponto de vista químico, tais correlações introduzem alta redundância na base de dados, justificando formalmente a aplicação de técnicas de redução de dimensionalidade como o PCA.

E. Análise de Componente Principal (PCA)

A Análise de Componentes Principais (PCA) é uma técnica não supervisionada de redução de dimensionalidade e transformação linear que projeta um conjunto de variáveis originalmente correlacionadas em um novo sistema de eixos ortogonais e mutuamente não correlacionados, denominados componentes principais. No contexto deste estudo, a projeção dos dados nos dois primeiros componentes principais (PC_1 e PC_2) permite sintetizar a informação dos 11 descritores físico-químicos em um espaço bidimensional, facilitando a visualização da variabilidade global e a avaliação da separabilidade estrutural entre as classes de qualidade do vinho.

A projeção bidimensional via PCA revelou um elevado grau de sobreposição entre as diferentes classes de qualidade, indicando ausência de separabilidade linear no plano das duas primeiras componentes principais. Contudo, observa-se uma leve tendência ao longo do eixo PC_1 , onde amostras de maior qualidade (notas 7 a 9) inclinam-se para valores negativos de PC_1 , associando-se a vinhos com maior teor alcoólico e menor densidade. O eixo PC_2 (acidez) não apresentou poder discriminatório claro. Adicionalmente, a presença de outliers extremos foi identificada em regiões periféricas da projeção.

TABLE IV
CARGAS DOS COMPONENTES PRINCIPAIS (PCA)

Preditor	PC1	PC2
fixed acidity	0,157218	0,587558
volatile acidity	0,005089	-0,051728
citric acid	0,144050	0,345295
residual sugar	0,427408	-0,008749
chlorides	0,212011	0,008800
free sulfur dioxide	0,300334	-0,290355
total sulfur dioxide	0,406652	-0,244032
density	0,511524	-0,006297
pH	-0,128832	-0,581344
sulphates	0,043379	-0,222695
alcohol	-0,437238	0,035569




Fig. 7. Projeção 2D - PCA

III. RESULTADOS

Este artigo teve como objetivo o estudo e preparo preliminar de dados de características de vinho branco português para o desenvolvimento e avaliação de modelos de inteligência computacional. Desse modo, pudemos realizar uma análise exploratória do conjunto de dados, destacando características importantes que terão influência significativa na construção de modelos baseados nesses dados. Podemos destacar a presença

numerosa de valores considerados discrepantes em *box-plots* na Figura 3, associados à elevada assimetria de algumas distribuições, como *chlorides* ($\gamma_{chlorides} = 5.02$), o que deverá ser tratado em etapas futuras da pesquisa por meio de transformações como *Spatial Sign Pre-processing*, que projeta os dados em uma esfera multidimensional, a fim de otimizar modelos lineares; e as relações de dependência entre variáveis como *density* e *residual sugar*, que forneceu suficiente motivação para a aplicação do método PCA de redução de dimensionalidade.

As análises concebidas permitiram a compreensão dos dados e a definição de etapas para seu pré-processamento, produzindo melhores condições para o desenvolvimento de modelos computacionais de regressão e classificação quanto à qualidade de vinhos, ferramenta poderosa para a indústria vinícola de alta qualidade, dada sua capacidade de filtragem preliminar de produtos com propriedades físico-químicas associadas a vinhos bem avaliados.

ACKNOWLEDGMENT

REFERENCES

- [1] P. Cortez, A. Cerdeira, Fernando Almeida, Telmo Matos, J. Reis. Wine Quality. Available: <https://archive.ics.uci.edu/dataset/186/wine+quality>
- [2] Kuhn, Max, and Kjell Johnson. Applied Predictive Modeling. Springer, 2018.
- [3] Serneels S, Nolf ED, Espen PV (2006). "Spatial Sign Pre-processing: A Simple Way to Impart Moderate Robustness to Multivariate Estimators." Journal of Chemical Information and Modeling, 46(3), 1402–1409.