Análise Exploratória, Redução de Dimensionalidade e Modelagem Não Linear na Avaliação da Qualidade de Vinhos

João Victor Carneiro de Oliveira
Departamento de Engenharia de Teleinformática (DETI)
Universidade Federal do Ceará (UFC)
Fortaleza, Brasil
vcovictor@alu.ufc.br

Leonardo Dayvison S. de Almeida Teixeira
Departamento de Engenharia de Teleinformática (DETI)
Universidade Federal do Ceará (UFC)
Fortaleza, Brasil
leodayvison@alu.ufc.br

Ludmila Maria Pires de Oliveira
Departamento de Engenharia de Teleinformática (DETI)
Universidade Federal do Ceará (UFC)
Fortaleza, Brasil
ludmilamariapo55@gmail.com

Maria Lissa Rodrigues Costa
Departamento de Engenharia de Teleinformática (DETI)
Universidade Federal do Ceará (UFC)
Fortaleza, Brasil
marialissa@alu.ufc.br

***Abstract*—Este trabalho investiga a previsão da qualidade de vinhos brancos a partir de suas propriedades físico-químicas, utilizando 4.898 amostras do conjunto Wine Quality. Após uma análise exploratória baseada em correlações de Pearson, aplicou-se um pré-processamento com transformação logarítmica, padronização e Análise de Componentes Principais (PCA), com parâmetros estimados exclusivamente no treinamento para evitar data leakage. Foram comparados os modelos: Regressão Linear por Mínimos Quadrados Ordinários (OLS), Regressão Ridge, Regressão por Mínimos Quadrados Parciais (PLS) e uma Rede Neural Artificial (MLP). Os modelos lineares estagnaram em R^2 entre 0,23 e 0,28 no conjunto de teste, caracterizando underfitting estrutural, enquanto a rede neural alcançou R^2 de 0,3519 e RMSE de 0,7085. Os resultados indicam uma relação essencialmente não linear entre a composição físico-química e a avaliação sensorial.**

***Index Terms*—qualidade de vinhos, regressão linear, PCA, PLS, redes neurais.**

I. Introdução

Na indústria vinícola, a qualidade de um vinho é tradicionalmente aferida por provadores treinados, cujas notas orientam a certificação dos produtos. Contudo, a avaliação sensorial é custosa e subjetiva, o que motiva o desenvolvimento de métodos objetivos capazes de apoiá-la.

Nesse sentido, as medições físico-químicas, como acidez, açúcar residual, cloretos, dióxido de enxofre, densidade, pH, sulfatos e teor alcoólico, podem ser utéis para o desenvolvimento de um modelo preditor objetivo, considerando que são rotineiras e de baixo custo. O conjunto de dados utilizado neste estudo reúne 4.898 amostras de vinho branco, cada uma descrita por 11 variáveis preditoras contínuas, tais como as citadas, e por uma nota de qualidade atribuída por avaliadores humanos. Esses preditores, porém, possuem escalas distintas, distribuições assimétricas e correlações entre si, o que exige um tratamento cuidadoso antes da modelagem.

Diante disso, este trabalho avalia a capacidade preditiva de modelos lineares (OLS, Ridge e PLS) e de uma rede neural do tipo MLP na estimativa da qualidade de vinhos brancos, com base no conjunto de dados apresentado, além de testar a hipótese de que a relação entre as variáveis é não linear. Para isso, realiza-se uma análise exploratória das correlações entre preditores e desfecho, seguida de um pipeline de pré-processamento com controle rigoroso de vazamento de informação e de avaliação por validação cruzada e conjunto de teste isolado.

Os autores agradecem à Professora Doutora Michela Mulas pela orientação e contribuições técnicas durante o desenvolvimento deste artigo.

II. Metodologia

Nesta seção, é apresentada a metodologia utilizada para a previsão da qualidade do vinho a partir de suas propriedades físico-químicas. Inicialmente, detalham-se as características gerais do conjunto de dados e o protocolo de divisão entre os conjuntos de treinamento e teste. Em seguida, descreve-se o pipeline de pré-processamento, englobando a transformação logarítmica de variáveis assimétricas, a padronização e a redução de dimensionalidade via Análise de Componentes Principais (PCA). Por fim, formalizam-se as fundamentações teóricas e as formulações matemáticas dos quatro modelos preditivos avaliados no estudo: a Regressão Linear por Mínimos Quadrados Ordinários (OLS), a Regressão Ridge (L_2), a Regressão por Mínimos Quadrados Parciais (PLS) e a Rede Neural Artificial (MLP).

A. Descrição Preliminar dos Dados

O conjunto de dados utilizado neste estudo engloba 4.898 amostras de vinho branco, cada uma caracterizada por 11

variáveis preditoras de natureza físico-química contínua, tais como acidez fixa e volátil, ácido cítrico, açúcar residual, cloretos, dióxido de enxofre livre e total, densidade, pH, sulfatos e teor alcoólico. A variável de desfecho (resposta) é a qualidade do vinho, que consiste em uma avaliação sensorial humana pontuada em uma escala tipicamente variando de 3 a 9.

Para assegurar uma avaliação rigorosa e imparcial da capacidade de generalização dos modelos, o conjunto de dados original foi particionado seguindo a proporção de 80/20. Consequentemente, o processo de aprendizado dos algoritmos foi conduzido sobre um **conjunto de treinamento composto por 3.918 observações**, reservando-se as **980 amostras restantes para compor o conjunto de teste**. Este último atua como um simulador de dados inéditos no mundo real e foi mantido estritamente isolado durante a etapa de modelagem.

O pré-processamento das características físico-químicas foi aplicado de forma a garantir a estabilidade numérica dos modelos preditivos e, primordialmente, evitar qualquer vazamento de informações metodológicas (*data leakage*) entre os dados de treino e teste. Inicialmente, variáveis que sabidamente apresentam distribuições altamente assimétricas, como o açúcar residual e o dióxido de enxofre livre, foram submetidas a uma transformação logarítmica (especificamente $\log(1 + x)$). Essa etapa visa reduzir o peso de valores extremos (*outliers*) e aproximar a distribuição das variáveis a uma curva normal, requisito desejável para modelos baseados em regressão linear.

Na sequência, todas as variáveis preditoras foram padronizadas, de modo a apresentarem média zero e variância unitária. Esta etapa de escalonamento é crítica, pois características medidas em grandezas físicas e químicas distintas (como densidade e dióxido de enxofre total) poderiam introduzir um viés de magnitude nos algoritmos de minimização de custo, independentemente de sua real importância preditiva. Para a abordagem de modelos que requerem controle de multicolinearidade e alta dimensionalidade, aplicou-se também a Análise de Componentes Principais (PCA), parametrizada para reter 90% da variância total explicada pelo conjunto original.

É fundamental ressaltar que os parâmetros matemáticos do pré-processamento, médias, desvios-padrão e os autovetores da matriz de covariância do PCA, foram calculados exclusivamente a partir do conjunto de treinamento. O conjunto de teste foi apenas transformado matematicamente com base nestes parâmetros previamente aprendidos, a fim de manter a integridade do experimento.

B. Regressão Linear por Mínimos Quadrados Ordinários (OLS)

A Regressão Linear por Mínimos Quadrados Ordinários (OLS) foi o primeiro modelo avaliado para estimar a qualidade dos vinhos brancos a partir de suas propriedades físico-químicas. Sob a perspectiva teórica, o OLS busca determinar um hiperplano parametrizado por um vetor de coeficientes $\boldsymbol{\beta}$ que minimize a soma dos resíduos quadráticos entre os

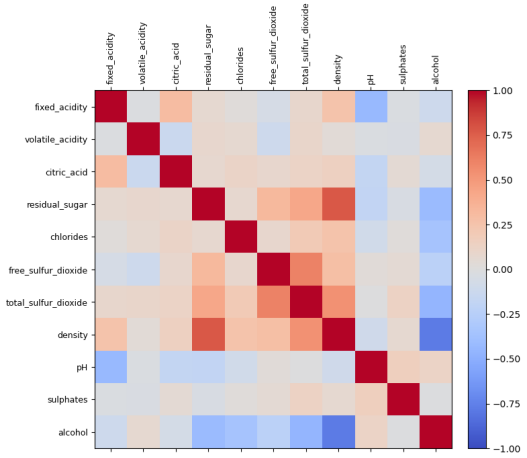


Fig. 1. Matriz de correlação de Pearson entre as variáveis preditoras transformadas. O mapa de calor (*heatmap*) ilustra as inter-relações lineares entre os atributos físico-químicos, permitindo identificar pares de alta colinearidade (destacados em tons mais intensos de azul ou vermelho), que justificam o uso de técnicas de regularização e redução de dimensionalidade nas etapas de modelagem.

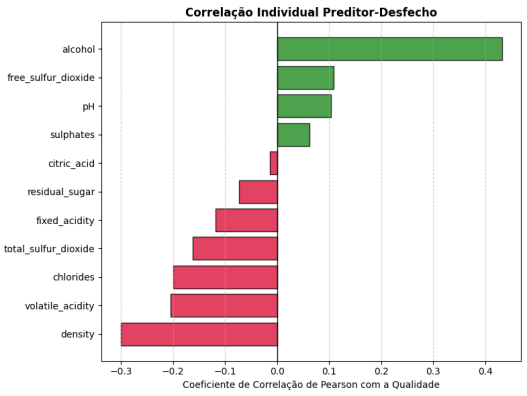


Fig. 2. Correlação individual de Pearson entre cada preditor físico-químico e a variável de desfecho (qualidade do vinho). Variáveis com barras voltadas à direita indicam uma associação linear positiva com avaliações sensoriais mais altas, enquanto barras voltadas à esquerda indicam associação negativa.

valores observados e as predições. A solução analítica é obtida diretamente pela Equação Normal:

$$\boldsymbol{\beta} = (\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T\mathbf{y} \tag{1}$$

Para verificar a exatidão da solução matricial desenvolvida, os coeficientes obtidos via Equação Normal foram comparados aos calculados pelas rotinas computacionais padrão da biblioteca *scikit-learn*. Conforme apresentado na Tabela I, a diferença absoluta máxima entre os coeficientes foi de 3.34×10^{-15}, uma variação numérica insignificante atribuída estritamente à precisão de ponto flutuante do ambiente de computação. Esse resultado valida rigorosamente a implementação algébrica do modelo.

A avaliação do processo de aprendizado foi conduzida por meio de validação cruzada de 5 vias (*5-fold cross-validation*) aplicada exclusivamente sobre o conjunto de treinamento. Essa

TABLE I
COMPARAÇÃO DE MÉTRICAS E COEFICIENTES ENTRE A IMPLEMENTAÇÃO ALGÉBRICA (DO ZERO) E A BIBLIOTECA DE REFERÊNCIA PARA O MODELO OLS.

Abordagem	**RMSE (CV)**	R^2 **(CV)**	**RMSE (Teste)**	R^2 **(Teste)**
OLS (Do Zero)	0,7492	0,2839	0,7457	0,2819
OLS (*scikit-learn*)	0,7492	0,2839	0,7457	0,2819

técnica de reamostragem é fundamental para estimar a capacidade de generalização do modelo de forma imparcial, evitando o otimismo de avaliações realizadas no próprio conjunto de ajuste. A validação cruzada resultou em um erro quadrático médio (RMSE) de 0,7492 e um coeficiente de determinação (R^2) de 0,2839.

Ao aplicar o modelo final ajustado ao conjunto de teste intocado, obteve-se um RMSE de 0,7457 e um R^2 de 0,2819. A alta convergência entre a estimativa de erro obtida na validação cruzada (0,7492) e o desempenho real no conjunto de teste (0,7457) confirma a ausência de *overfitting* (sobreajuste), demonstrando que o modelo mantém sua consistência ao lidar com dados inéditos.

Entretanto, o coeficiente de determinação obtido ($R^2 \approx 0,2819$) revela uma limitação estrutural do modelo linear, que é capaz de explicar apenas 28,19% da variância total da qualidade do vinho. Essa limitação expressa um cenário clássico de *underfitting* (subajuste) decorrente da premissa de linearidade.

O comportamento observado no gráfico de dispersão da Figura 3 corrobora visualmente essa limitação. Em um modelo ideal, as estimativas estariam estritamente alinhadas sobre a diagonal tracejada vermelha ($y = x$). No entanto, a distribuição das predições forma uma nuvem dispersa concentrada na faixa central (notas 5 e 6). O modelo atua de forma conservadora ao prever valores próximos à média global para quase todas as amostras, apresentando forte incapacidade de prever os valores extremos de qualidade (notas 3, 4, 8 e 9). Conclui-se que as interações entre as variáveis físico-químicas e a avaliação sensorial de qualidade possuem natureza não linear complexa, demandando arquiteturas de modelagem mais flexíveis.

C. Regressão Linear Penalizada por Regularização L_2 (Ridge Regression)

Para lidar com a colinearidade residual entre os preditores físico-químicos e controlar a variância do modelo, aplicou-se a Regressão Ridge sobre as componentes principais extraídas na etapa de pré-processamento. A abordagem insere um termo de penalização quadrático (L_2) à função de custo dos Mínimos Quadrados Ordinários, parametrizado pelo hiperparâmetro $\lambda \geq 0$. Sob a perspectiva teórica, a solução analítica para a estimativa dos coeficientes $\boldsymbol{\beta}$ é dada por:

$$\boldsymbol{\beta} = (\mathbf{X}^T\mathbf{X} + \lambda\mathbf{I}^*)^{-1}\mathbf{X}^T\mathbf{y} \tag{2}$$

em que $\mathbf{I}^*$ representa uma matriz identidade modificada, na qual o elemento correspondente ao intercepto (β_0) é definido como zero para evitar a penalização da constante do modelo.

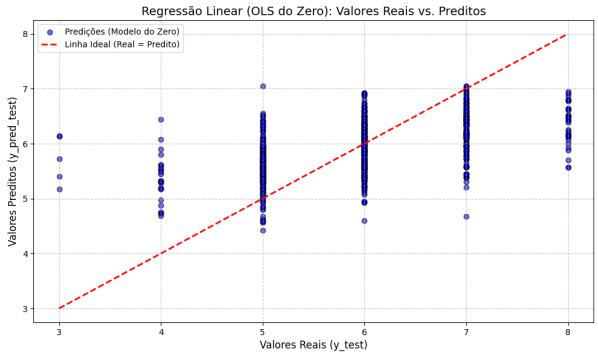


Fig. 3. Desempenho do modelo OLS no conjunto de teste: comparação entre os valores reais de qualidade do vinho e as predições geradas. A linha tracejada vermelha indica o cenário hipotético de acerto perfeito ($y = x$). A dispersão dos pontos evidencia a tendência do modelo em prever valores próximos à média, caracterizando o *underfitting* estrutural da abordagem linear.

A validação da implementação analítica desenvolvida do zero foi realizada comparando-se os coeficientes resultantes aos obtidos pela classe *Ridge* do pacote *scikit-learn* sob o mesmo valor de λ. A Tabela II consolida o desempenho obtido e evidencia que a diferença absoluta máxima entre os coeficientes calculados foi de 3.33×10^{-16}, confirmando a exatidão da solução matricial até o limite da precisão de ponto flutuante.

TABLE II
DESEMPENHO FINAL E VERIFICAÇÃO DE EQUIVALÊNCIA ALGÉBRICA PARA A REGRESSÃO RIDGE (L_2).

Abordagem	λ **Ideal**	**Dif. Máx. Coef.**	**RMSE (Teste)**	R^2 **(Teste)**
Ridge (Do Zero)	35,5648	3.33×10^{-16}	0,7740	0,2265
Ridge (*sklearn*)	35,5648	—	0,7740	0,2265

A determinação do hiperparâmetro ideal foi conduzida por meio de validação cruzada de 5 vias sobre o conjunto de treinamento, varrendo um espaço de busca logarítmico composto por 50 valores de λ. A otimização minimizou o erro quadrático médio (RMSE), identificando o valor ótimo de $\lambda = 35.5648$. Essa intensidade de penalização atua encolhendo a magnitude dos coeficientes para estabilizar a variância estimada a partir das componentes principais.

No conjunto de teste intocado, o modelo final Ridge obteve um RMSE de 0,7740 e um R^2 de 0,2265. Em comparação com o modelo OLS simples (que obteve $R^2 \approx 0,2819$), a adição da penalização L_2 combinada com a redução de dimensionalidade por PCA não resultou em ganho preditivo; ao contrário, apresentou um ligeiro decréscimo de precisão. Esse resultado confirma que a limitação na capacidade explicativa do modelo não decorre do sobreajuste (*overfitting*) ou de instabilidade provocada por multicolinearidade, mas sim do fato de que a relação subjacente entre os atributos físico-químicos e a qualidade do vinho possui um comportamento inerentemente não linear.

O comportamento observado ao longo da validação cruzada e no teste final é ilustrado nas Figuras 4 e 5.

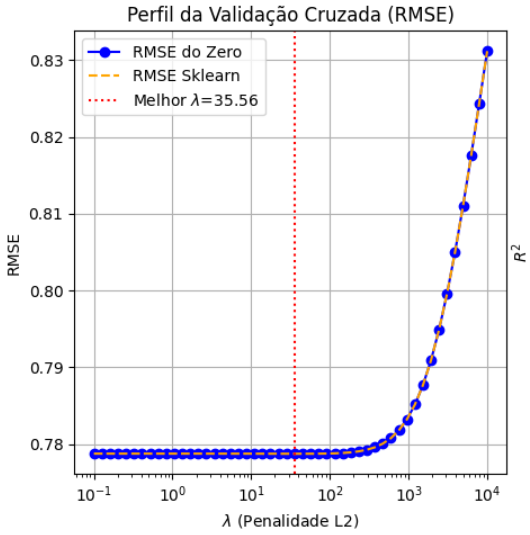


Fig. 4. O gráfico exibe a evolução do erro quadrático médio (RMSE), demonstrando a sobreposição perfeita entre a implementação do zero e a do *scikit-learn*.

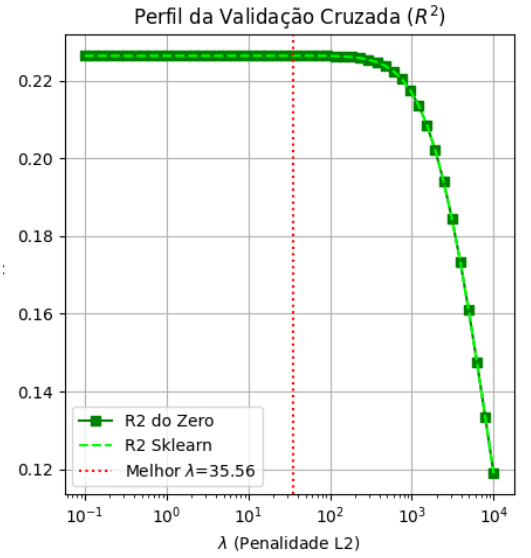


Fig. 5. O gráfico apresenta a variação do coeficiente de determinação (R^2), também com equivalência exata entre as implementações. Em ambos os painéis, a linha vertical tracejada vermelha marca o hiperparâmetro ideal encontrado ($\lambda = 35.56$). À direita deste ponto (valores maiores de λ), a penalidade excessiva esmaga os coeficientes, resultando em um aumento exponencial do RMSE e uma queda abrupta do R^2, o que caracteriza um cenário de subajuste (*underfitting*) induzido por regularização.

D. Regressão por Mínimos Quadrados Parciais (PLS)

Como alternativa à extração não supervisionada de características do PCA combinada com a Regressão Ridge, avaliou-se a Regressão por Mínimos Quadrados Parciais (PLS). O algoritmo PLS difere fundamentalmente das abordagens anteriores por ser um método supervisionado de redução de dimensionalidade. Ele busca projetar os dados originais em um novo espaço de componentes latentes ortogonais que não apenas resumam a variância dos preditores físico-químicos, mas que simultaneamente maximizem a correlação geométrica com a variável de resposta (a qualidade do vinho).

A seleção do hiperparâmetro estrutural — o número de componentes latentes — foi conduzida através de um rigoroso algoritmo de Validação Cruzada (CV) isolado no conjunto de treinamento, prevenindo qualquer vazamento de informações (*data leakage*). A análise do perfil de validação revela que o erro estimativo (RMSE) apresenta uma queda drástica do primeiro ao quarto componente, ponto em que atinge seu mínimo global absoluto. Simultaneamente, a capacidade explicativa medida pelo R^2 atinge seu pico máximo de eficiência exatamente nesta arquitetura de 4 dimensões. A inclusão de um quinto componente em diante promove uma estabilização do RMSE com leve tendência de alta e o declínio do R^2, indicando que o modelo passa a capturar ruídos estocásticos em vez de sinal preditivo útil. A otimização matemática confirmou o ponto ótimo, fixando a arquitetura final em 4 componentes latentes.

TABLE III
RESULTADOS DA OTIMIZAÇÃO ESTRUTURAL E MÉTRICAS DE GENERALIZAÇÃO PARA O MODELO PLS.

Modelo	Componentes Ideais	RMSE (CV)	RMSE (Teste)	R^2 (Teste)
PLS	4	0,7461	0,7459	0,2816

A validação da robustez e capacidade de generalização do modelo é evidenciada na Tabela III. O RMSE estimado pela validação cruzada no treinamento (0,7461) convergiu quase perfeitamente com o erro real medido no conjunto de teste intocado (0,7459). Essa expressiva proximidade numérica descarta a presença de *overfitting* e comprova que o fluxo de pré-processamento (no qual a padronização foi ajustada exclusivamente no treino e apenas aplicada ao teste) foi executado com alto rigor metodológico.

Apesar da generalização correta e do fato de o PLS ter cumprido sua função ao comprimir a redundância química em apenas 4 componentes ortogonais, o modelo obteve um R^2 de 0,2816 no teste. Esse ganho de precisão é apenas marginal quando comparado ao modelo OLS clássico (que obteve $R^2 \approx 0,2819$). A capacidade preditiva bruta permanece restringida pela natureza linear do algoritmo. Tais resultados são inteiramente coerentes com o comportamento dos modelos lineares anteriores: a barreira de desempenho consolidada nos três experimentos (OLS, Ridge e PLS) atesta de forma contundente que a relação subjacente entre os compostos físico-químicos e a nota de qualidade do vinho é inerentemente não linear, configurando um limite estrutural de subajuste

(*underfitting*) incontornável para hiperplanos matemáticos estritos.

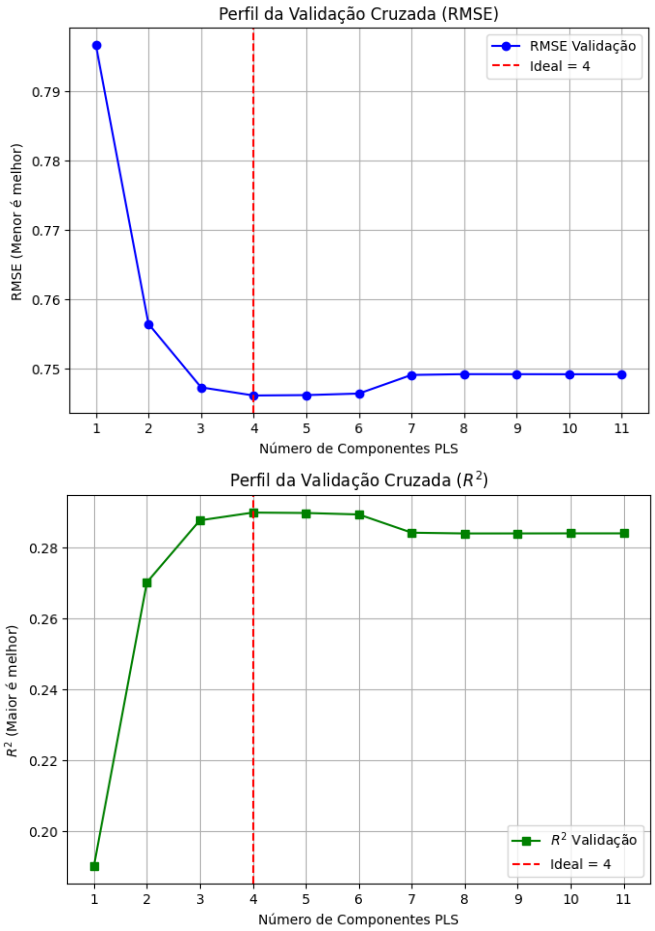


Fig. 6. Perfil da validação cruzada para seleção de hiperparâmetro no modelo PLS. O gráfico à esquerda demonstra o decaimento acentuado do Erro Quadrático Médio (RMSE), que encontra seu limite mínimo exato na marca de 4 componentes latentes (linha tracejada vermelha). O gráfico à direita ilustra o pico correspondente na métrica de proporção de variância explicada (R^2). Em ambos os cenários, adicionar mais de 4 dimensões (5 a 11) não agrega poder preditivo e inicia um processo incipiente de degradação e ajuste a ruídos.

E. Modelagem Não Linear: Redes Neurais Artificiais

Para investigar a hipótese de que a relação entre as propriedades físico-químicas do vinho e sua qualidade percebida possui natureza complexa e multifacetada, implementou-se um modelo não linear baseado em Redes Neurais. Diferente dos modelos lineares, que assumem variações estritamente proporcionais (onde o aumento de um componente como o açúcar residual invariavelmente aumenta ou diminui a nota na mesma proporção), a arquitetura neural utiliza funções de ativação não lineares. Isso a torna capaz de mapear interações multidimensionais intrincadas — como o fato de o açúcar melhorar o paladar da bebida até certo limiar, mas degradá-lo caso não haja uma acidez proporcional para contrabalançar.

Os resultados finais computados pelo algoritmo demonstram um ganho substancial em relação às abordagens anteriores, conforme sumarizado na Tabela IV.

TABLE IV
DESEMPENHO DA REDE NEURAL NO CONJUNTO DE TESTE.

Modelo	**RMSE (Teste)**	R^2 **(Teste)**
Rede Neural	0,7085	0,3519

Nas experimentações anteriores, os algoritmos estritamente lineares (OLS, Ridge e PLS) estagnaram em um R^2 entre 0,25 e 0,28, com o RMSE estacionado na faixa de 0,75. A Rede Neural, por sua vez, baixou o RMSE para 0,7085 e elevou o R^2 para 0,3519.

Respondendo à questão principal do enunciado: **Sim, o modelo não linear superou todos os modelos lineares desenvolvidos anteriormente**. Houve um ganho claro de aproximadamente 7 a 10 pontos percentuais na variância explicada (R^2). Esse comportamento confirma em definitivo a hipótese levantada nas etapas anteriores: a relação subjacente nos dados é fundamentalmente não linear. Graças à sua maior flexibilidade matemática, a rede neural consegue escapar, ainda que parcialmente, da ”gravidade” da média global (vinhos notas 5 e 6), arriscando predições mais assertivas e alinhadas para os vinhos de notas extremas.

A dinâmica e a estabilidade desse aprendizado podem ser analisadas visualmente por meio da evolução do erro interno da rede durante o treinamento, ilustrada na Figura 7.

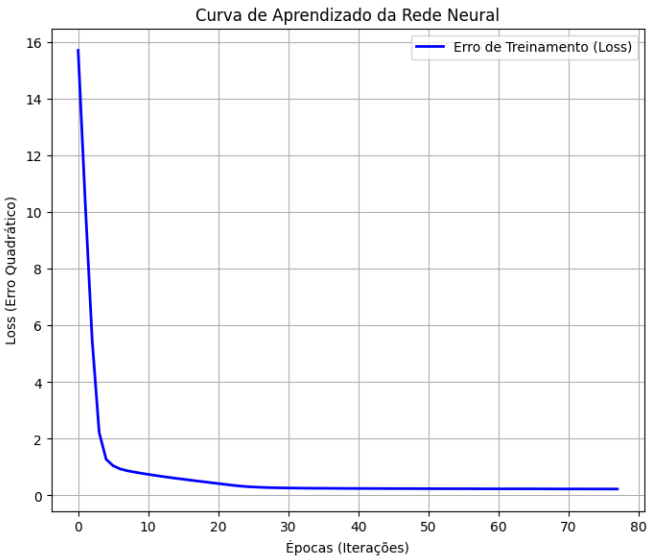


Fig. 7. Curva de aprendizado (*Loss Curve*) da Rede Neural. O gráfico evidencia a evolução do erro interno do modelo (Erro Quadrático, eixo vertical) ao longo das iterações ou épocas de treinamento (eixo horizontal). Observa-se o comportamento teórico ideal: a curva despenca rapidamente nas iterações iniciais (quando a rede descobre os padrões mais óbvios que relacionam a química ao paladar) e, em seguida, transiciona para um platô suave. A interrupção abrupta do gráfico antes da época 80 indica a atuação do mecanismo de *early stopping* (parada antecipada). Esse recurso interrompeu o treinamento no momento exato em que o modelo atingiu seu equilíbrio, prevenindo que a rede começasse a memorizar ruídos e sofresse de *overfitting*.

III. Resultados

A análise dos resultados obtidos evidencia diferenças no desempenho preditivo das abordagens avaliadas. Inicialmente, observa-se que os modelos lineares apresentaram resultados relativamente próximos, com valores de R^2 entre 0,226 e 0,2819, sendo o modelo OLS o de melhor desempenho entre eles, alcançando RMSE de 0,7457 e R^2 de 0,2819 no conjunto de teste. O PLS apresentou resultados praticamente equivalentes, com RMSE de 0,7459 e R^2 de 0,28, enquanto o Ridge apresentou desempenho inferior, com RMSE de 0,7740 e R^2 de 0,2265.

No caso do OLS, a proximidade entre as métricas de validação cruzada e teste, RMSE de 0,7492 e 0,7457, respectivamente, indica consistência na estimativa de generalização. Tal comportamento também foi observado no PLS, cujos valores de RMSE foram de 0,7461 na validação cruzada e 0,7459 no teste. Esses resultados sugerem que ambos os modelos mantiveram desempenho estável diante de amostras não utilizadas no ajuste.

A aplicação da regularização Ridge, por sua vez, não proporcionou melhorias em relação ao OLS. Mesmo com a seleção do hiperparâmetro $\lambda = 35,56$ por validação cruzaa, o modelo apresentou uma redução na capacidade explicativa. De maneira semelhante, a utilização de quatro componentes latentes no PLS não resultou em ganhos expressivos, indicando que as estratégias de regularização e redução linear de dimensionalidade não foram suficientes para ampliar significativamente a capacidade preditiva dos modelos.

Por fim, diferentemente das abordagens anteriores, a Rede Neural Artificial (MLP) apresentou o melhor desempenho geral, alcançando RMSE de 0,7085 e R^2 de 0,3519 no conjunto de teste. Em comparação ao OLS, esse resultado representa uma redução de aproximadamente 5% no erro de predição e um aumento na variância explicada, o que sugere que a capacidade de representar relações não lineares e interações entre variáveis permite à rede neural identificar padrões adicionais presentes nos dados.

É válido destacar que, ainda que seja perceptível da superioridade da MLP, favorecendo a utilização de abordagens não lineares para a previsão da qualidade dos vinhos, seu coeficiente de determinação demonstra que aproximadamente 64,81% da variabilidade das avaliações sensoriais ainda permanece sem explicação pelo modelo, evidenciando aa complexidade da relação entre a composição do vinho e sua avaliação sensorial.

Acknowledgment

References

[1] P. Cortez, A. Cerdeira, Fernando Almeida, Telmo Matos, J. Reis. Wine Quality. Avaliable: https://archive.ics.uci.edu/dataset/186/wine+quality

[2] Kuhn, Max, and Kjell Johnson. Applied Predictive Modeling. Springer, 2018.

[3] Serneels S, Nolf ED, Espen PV (2006).“Spatial Sign Pre-processing: A Simple Way to Impart Moderate Robustness to Multivariate Estimators.” Journal of Chemical Information and Modeling, 46(3), 1402–1409.